# Examen de mi-session

**Consignes.** Cet examen comporte 18 questions et totalise 100 points. Répondez à toutes les questions. Pour les choix multiples, cochez une seule réponse, sauf indication contraire. Écrivez du code complet lorsqu'il est demandé.

## **Question 1** — Inspection d'un tableau — 5 pts

Vous importez un fichier CSV très large appelé `donnees.csv` dans R sous le nom `d`. Il contient 1 050 colonnes. Quelle commande fournit l'aperçu le plus utile de la structure et des variables du tableau?

a) ☐ `print(d)`
b) ☐ `glimpse(d)`
c) ☐ `names(d)`
d) ☐ `head(d)`

## **Question 2** — Signal et bruit — 3 pts

Deux études comparent deux groupes. Dans les deux études, l'écart entre les moyennes est le même, tout comme la taille des échantillons. Dans l'étude B, toutefois, les scores varient beaucoup plus à l'intérieur de chaque groupe que dans l'étude A. Que peut-on dire de la statistique $t$ de l'étude B?

a) ☐ Elle est plus éloignée de 0 que celle de l'étude A, car la variation est plus grande.
b) ☐ Elle est identique à celle de l'étude A, car l'écart entre les moyennes est le même.
c) ☐ Elle est plus proche de 0 que celle de l'étude A, car le bruit est plus grand.
d) ☐ Elle ne peut pas être calculée, car les variances des groupes sont inégales.

## **Question 3** — Interprétation d'une valeur $p$ — 5 pts

Vous obtenez une valeur $p$ de 0,03. Quelle interprétation est correcte?

a) ☐ La probabilité que l'hypothèse nulle soit vraie est de 3 %.
b) ☐ La probabilité que les résultats soient dus au hasard est de 97 %.
c) ☐ Si l'hypothèse nulle est vraie, la probabilité d'observer des données au moins aussi extrêmes est de 3 %.
d) ☐ La probabilité de commettre une erreur de type I est de 3 %.

## **Question 4** — Pipeline incomplet — 5 pts

Observez le code suivant et identifiez l'erreur.

```
donnees |>
  filter(age > 18) |>
  select(nom, score) mutate(score_double = score * 2)
```

a) ☐ `filter()` devrait être remplacée par `subset()`.
b) ☐ Il manque `|>` avant `mutate()`.
c) ☐ `select()` et `mutate()` ne peuvent pas être utilisées ensemble.
d) ☐ `score * 2` devrait être entre guillemets.

**Question 5** — Degrés de liberté 5 pts

Dans une ANOVA à un facteur, vous obtenez $F(2, 57) = 4{,}82$, $p = 0{,}012$. Combien de groupes sont comparés?

a) ☐ 2 groupes.
b) ☐ 57 groupes.
c) ☐ 3 groupes.
d) ☐ 60 groupes.

**Question 6** — Moyenne par condition 8 pts

Un tibble appelé `donnees` contient les colonnes `participant`, `condition` et `temps`. Écrivez le code complet pour calculer le temps moyen par condition et conserver le résultat dans un objet appelé `moyennes`.

**Question 7** — Nuage de points 5 pts

Quelle géométrie de `ggplot2` crée un nuage de points?

a) ☐ `geom_point()`
b) ☐ `geom_scatter()`
c) ☐ `geom_plot()`
d) ☐ `geom_dots()`

**Question 8** — Pente d'une régression 6 pts

Dans une régression linéaire, vous obtenez $\hat{\beta}_1 = -2{,}3$. Que signifie ce coefficient?

a) ☐ Quand $x$ augmente de 1, $y$ diminue de 1.
b) ☐ Quand $y$ augmente de 1, $x$ diminue de 2,3.
c) ☐ La corrélation entre $x$ et $y$ est de $-2{,}3$.
d) ☐ Quand $x$ augmente de 1, la valeur prévue de $y$ diminue de 2,3.

**Question 9** — Passage au format long 7 pts

Observez le tableau `d` :

```
id  pre  post
1   45   52
2   38   41
3   50   55
```

Écrivez le code qui le transforme au format long avec les colonnes `id`, `temps` et `score`, puis attribuez le résultat à `d_long`.

**Question 10** — Hypothèse nulle de l'ANOVA 5 pts

Dans une ANOVA, que stipule l'hypothèse nulle?

a) ☐ Au moins deux moyennes sont différentes.
b) ☐ Toutes les moyennes sont différentes.
c) ☐ Toutes les moyennes de population sont égales.
d) ☐ La variance observée est nulle dans chaque groupe.

**Question 11** — ANOVA et comparaisons *post hoc* 6 pts

Une ANOVA portant sur cinq groupes donne $p = 0{,}02$. Cochez **toutes** les affirmations correctes.

a) ☐ L'ANOVA indique précisément quels groupes diffèrent.
b) ☐ Un test *post hoc* est nécessaire pour localiser les différences.
c) ☐ L'ajustement des valeurs $p$ d'un test *post hoc* vise surtout à contrôler les erreurs de type II.
d) ☐ Au moins une moyenne diffère statistiquement d'au moins une autre.

**Question 12** — Prédicteur catégoriel 8 pts

Vous ajustez `lm(temps ~ age + genre, data = d)` et obtenez :

```
(Intercept)  120.5
age           -2.1
genreM        15.3
```

Interprétez `genreM` en supposant que le groupe de référence est `F`.

**Question 13** — Création d'une variable 5 pts

Quelle fonction de `dplyr` sert à créer ou modifier une colonne?

a) ☐ `create()`
b) ☐ `add_column()`
c) ☐ `mutate()`
d) ☐ `select()`

**Question 14** — Filtrage combiné 7 pts

À partir de l'objet `donnees`, conservez les observations où `age > 25` **et** `score < 80`, puis attribuez le résultat à `sous_ensemble`.

**Question 15** — Résultat non significatif 5 pts

Un test $t$ donne $p = 0{,}08$ avec $\alpha = 0{,}05$. Quelle conclusion est correcte?

a) ☐ On rejette $H_0$; le résultat est significatif.
b) ☐ On ne rejette pas $H_0$; le résultat n'est pas statistiquement significatif au seuil choisi.
c) ☐ On accepte que $H_0$ est vraie.
d) ☐ Le test $t$ est nécessairement invalide.

**Question 16** — Coefficient de détermination 6 pts

Dans une régression linéaire, que représente le $R^2$?

a) ☐ La proportion de la variation de la réponse expliquée par le modèle.
b) ☐ La corrélation brute entre $x$ et $y$.
c) ☐ La pente de la droite de régression.
d) ☐ L'erreur standard des résidus.

**Question 17** — Rapport d'une ANOVA 4 pts

Observez le résultat suivant et rapportez l'ANOVA au format standard.

```
           Df  Sum Sq  Mean Sq  F value  Pr(>F)
facteur     3     450    150.0     5.23   0.003
Residuals  76    2180     28.7
```

**Question 18** — Suppression de colonnes 5 pts

Quelle fonction permet d'enlever des colonnes d'un tibble?

a) ☐ `remove()`
b) ☐ `drop()`
c) ☐ `filter()`
d) ☐ `select()`