

Problème 1

Consignes. Remettez un seul fichier PDF produit avec Quarto dans Posit Cloud. Utilisez le modèle du cours, masquez le code dans le document final et présentez les résultats importants dans le texte. Les figures doivent avoir des axes lisibles et une légende pertinente. Votre script et votre fichier de données doivent rester dans le même projet, mais seul le PDF est remis. Le travail totalise 100 points.

1. Les données

Le fichier `probleme_1.csv` contient 1 659 observations provenant d’une tâche de décision lexicale. Les participants doivent décider le plus rapidement possible si une chaîne correspond à un mot. La variable de réponse `RT` représente le logarithme naturel du temps de réaction en millisecondes. `Class` distingue les noms d’animaux et de plantes; `NativeLanguage` distingue les locuteurs natifs de l’anglais des autres locuteurs. Les variables `Sex`, `Word` et `Length` donnent des renseignements supplémentaires.

Les données sont adaptées du jeu `lexdec` distribué dans l’extension R `languageR`. Explorez le tableau avant de commencer et justifiez chacune de vos décisions analytiques.

Question 1 — Source des données

5 pts

Ajoutez dans votre introduction la citation bibliographique de l’extension `languageR`, puis faites apparaître la référence complète dans la bibliographie de votre PDF. Indiquez brièvement que les données ont été adaptées.

Question 2 — Structure du tableau

5 pts

Le tableau est-il tidy? Justifiez votre réponse en vous appuyant sur les unités d’observation et les variables.

Question 3 — Échelle du temps de réaction

10 pts

Créez une colonne `RTms` qui ramène `RT` à l’échelle originale en millisecondes. Montrez les six premières lignes et expliquez la transformation utilisée.

Question 4 — Temps de réaction par classe

10 pts

Calculez, pour chaque niveau de `Class`, le nombre d’observations, la moyenne et l’écart-type de `RTms`. Comparez les moyennes dans une phrase.

Question 5 — Longueur des mots

10 pts

Calculez la longueur minimale et maximale des mots dans chaque classe. Présentez le résultat dans un petit tableau.

Question 6 — Langue maternelle

10 pts

Calculez le temps de réaction moyen en millisecondes par niveau de `NativeLanguage`. Quel groupe est descriptivement le plus rapide? Distinguez explicitement description et inférence.

Question 7 — Visualisation

15 pts

Créez une figure qui permet d'examiner simultanément `RTms`, `Class` et `NativeLanguage`. Ajoutez un résumé visuel des moyennes. Décrivez le patron principal et dites quelle variable semble avoir l'effet le plus important.

Question 8 — Régression linéaire

15 pts

Ajustez le modèle `RT ~ Class + NativeLanguage` avec la version logarithmique de la réponse. Identifiez les niveaux de référence et interprétez complètement les coefficients, leurs intervalles de confiance à 95 %, les valeurs p et le R^2 . Votre conclusion doit répondre à la question soulevée par la figure.

Question 9 — Analyse de sensibilité

20 pts

Créez un nouveau tableau qui exclut les **observations** où `RT > 6.25`. Indiquez combien d'observations restent, reproduisez la figure et le modèle, puis comparez précisément les conclusions. Enfin, expliquez pourquoi un tel filtrage ne devrait jamais être appliqué sans justification préalable.